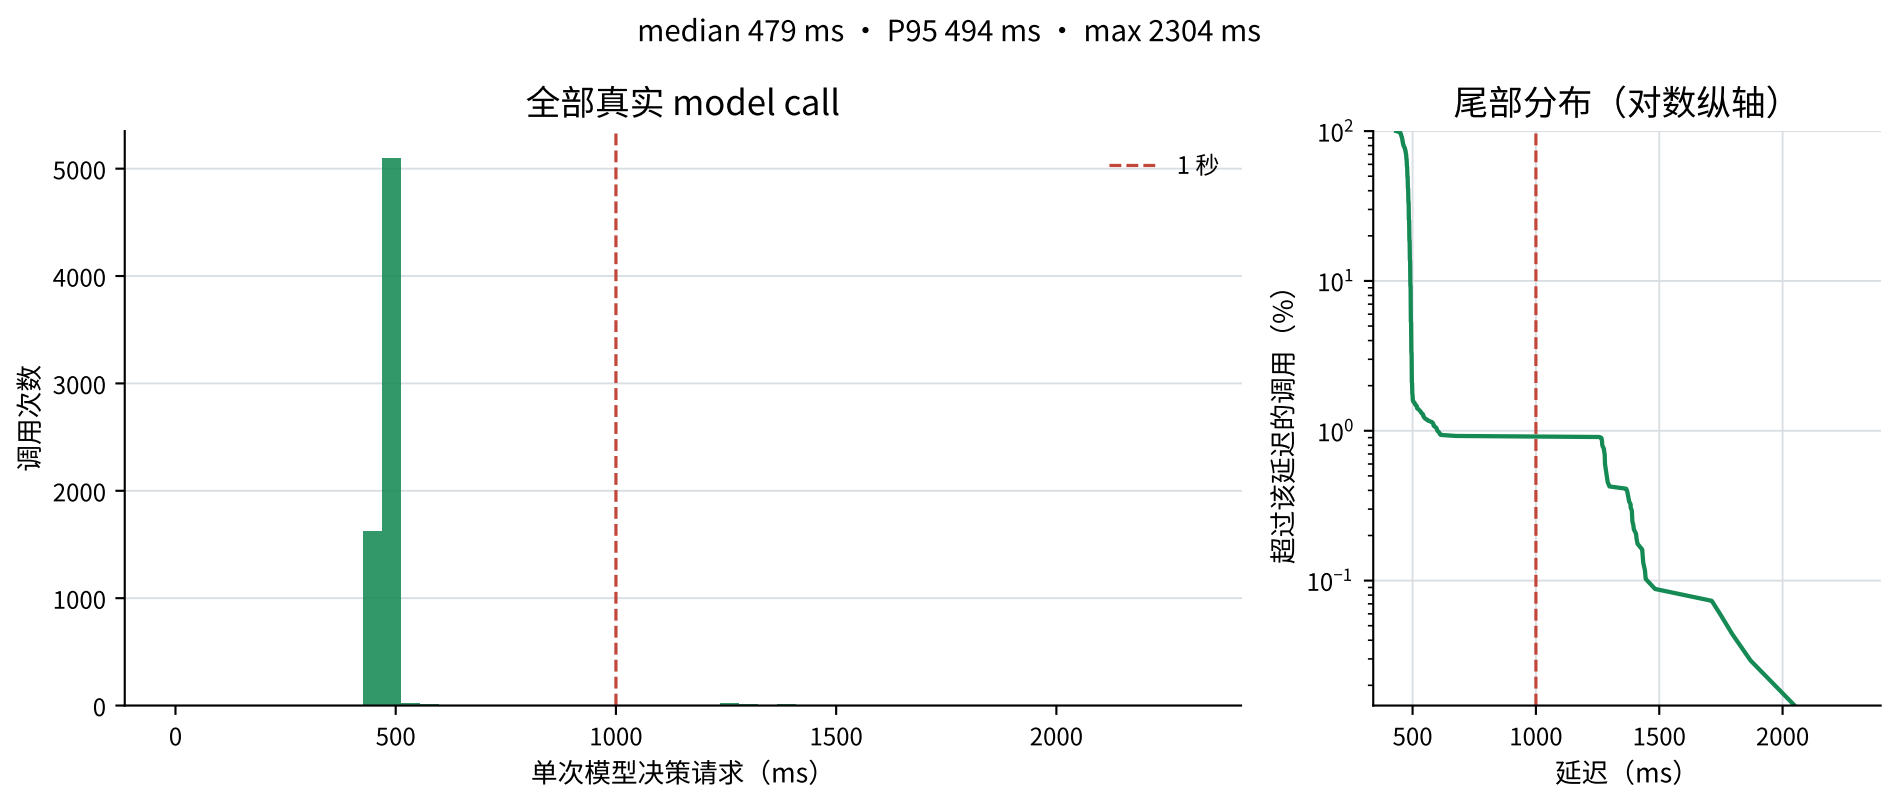
median 479 ms • P95 494 ms • max 2304 ms
全部真实 model call
1 秒
调用次数
单次模型决策请求（ms）
尾部分布（对数纵轴）
超过该延迟的调用（%）
延迟（ms）